

Deep Learning / ML – Klausur Spickzettel

Neuronale Netze

- Architektur lesen: Inputs → Hidden → Output
- Parameter zählen: Gewichte + Biases pro Layer
- Sigmoid am Output → Wertebereich (0,1)
- Ohne Aktivierung am Output → ■

Gradienten

- Quadratische Form: $\nabla(x^T M x) = (M + M^T)x$
- Richtungsableitung: $D_u f(x) = \nabla f(x)^T u$

Dropout

- Training: zufälliges Nullsetzen von Neuronen
- Evaluation: kein Dropout
- Wirkt als Regularisierung gegen Overfitting

Batch Normalization

- Reihenfolge: Linear/Conv → BN → ReLU
- Training: Batch-Statistiken
- Eval: running mean/variance
- Immer `model.train()` / `model.eval()` setzen

Convolution

- Same Padding: $\text{Output} \approx \text{ceil}(\text{Input} / \text{Stride})$
- Parameter: $\text{Kernel_h} \times \text{Kernel_w} \times \text{InChannels} \times \text{OutChannels}$
- Bias ggf. + OutChannels

Optimierung

- Learning Rate Schedules → stabilere Konvergenz
- Zu kleine LR → sehr langsames Lernen, Underfitting

Metriken

- Imbalanced Data → Accuracy ungeeignet
- Besser: Recall, Precision, F1, ROC-AUC

Object Detection

- CNN-Output: $h \times w \times \text{channels}$
- Conv statt FC → weniger Parameter, Ortsinformation bleibt